

ANALISIS DIVVY BIKE CHICAGO MENGGUNAKAN METODE ANALISIS GOOGLE ANALYTICS

OUTLINE

Objective: fictional bike-share company to **help them attract more riders**.

The director of marketing believes the company's future success depends on **maximizing the number of annual memberships**.

Therefore, your team wants to understand **how casual riders and annual members use Cyclistic bikes differently**.

From these insights, your team will design a new marketing strategy to convert casual riders into annual members.

Company: 5,824 bicycles ; 692 stations across Chicago

Main task

Business task: How do annual members and casual riders **use** Cyclistic bikes differently?

Stakeholders: director of marketing and manager, **Lily Moreno**.

Jika ada perbedaan yang jelas maka kita bisa melihat dari perbedaan itu dan mulai mendisrupsi perubahan dari perbedaan yang ada.

Defining

Mari definisikan dulu apa itu annual dan casual member.

Annual member: Customers who purchase annual memberships are Cyclistic members. People who has membership within a year. Pays a single fee for 12 months.

Casual riders: Customers who purchase single-ride or full-day passes are referred to as casual riders.

our main task would be to assest the difference between annual and casual riders therefor several questions we could ask would be:

ASK

What are the data that are available?

Trip data from 2013 to 2020 Q1

Include:

trip_id: ID attached to each trip taken

starttime: day and time trip started, in CST
stoptime: day and time trip ended, in CST
bikeid: ID attached to each bike
tripduration: time of trip in seconds
from_station_name: name of station where trip originated
to_station_name: name of station where trip terminated
from_station_id: ID of station where trip originated
to_station_id: ID of station where trip terminated
usertype: "Customer" is a rider who purchased a 24-Hour Pass; "Subscriber" is a rider who purchased an Annual Membership
gender: gender of rider
birthyear: birth year of rider

Trip data from 2020-04 to 2026-05

Include:

ride_id
rideable_type
started_at
ended_at
start_station_name
start_station_id
end_station_name
end_station_id
start_lat
start_lng
end_lat
end_lng
member_casual

Station data from 2013 to 2017

Include:

name: station name
latitude: station latitude
longitude: station longitude
dpcapacity: number of total docks at each station as
online date: date the station went live in the system

How does we process the data?

Kita akan menggabungkan dan melakukan standarisasi trip data dari 2013 ke 2026. Kita tetap akan membersihkan dan mengatur format station data tapi fokus utama kita sekarang tetap akan di trip data. Setelah trip data selesai prosesnya kita bisa mungkin butuh station data jadi kita akan tetap membersihkan dan menggabungkan data station. Dengan demikian, data kita akan ada 2 file spreadsheet yaitu trip dan station.

Apa yang menjadi definisi dari analisa yang sukses disini?


1. Kita bisa melihat perbedaan antara annual member dan casual member secara behavior dan sebagiannya.
2. Karena outline utama kita adalah bagaimana **convert casula member into annual member** dan **maximizing annual member** maka kita harus melihat juga apa kekuatan utama dari annual member yang bisa kita maksimalkan.

PREPARE

Kita akan mendownload semua data yang ada di <https://divvy-tripdata.s3.amazonaws.com/index.html> menyatukanya di folder trip dan station.

Ada mistake di file zip 202601-divvy-tripdata.zip yang mana isinya justru 202501-divvy-tripdata.xlsx – setelah di compere datanya berbeda sehingga hanya diubah nama filenya jadi 202601-divvy-tripdata.xlsx.

Karena ada dua format berbeda kita akan menyatukan dulu format yang sama menjadi 2 file besar sebelum di maringing.



trip	6/11/2026 10:44 AM	File folder
station	6/11/2026 10:09 AM	File folder

trip folder 8.80 GB with 104 Files

station folder 297 KB with 9 Files

because in speadsheet it cannot be done to analysis this much data therefor we used python or anaconda ipynb.

PROCESS

First, we will merge the same formate data into one. From xlsx to csv and marget it.

2013 to 2020	6/11/2026 12:10 PM	File folder
2020-4 to 2026-05	6/11/2026 12:09 PM	File folder

Setelah mencoba menyatukan csv dari 2013 to 2020 folder ternyata format mereka tidak sama walaupun format di download file namanya sama, sehingga membuat penyatuannya menjadi cukup tidak bagus. Dengan demikian, saya akan mengubah column yang tidak sama, dominan ada di 2018 Q1 dan 2020 yang ternyata lebih untuk folder ke dua.

```

trip_id      NaN
starttime   NaN
stoptime     NaN
bikeid       NaN
tripduration NaN
from_station_id NaN
from_station_name NaN
to_station_id NaN
to_station_name NaN
usertype     NaN
gender       NaN
birthday     NaN
birthyear    NaN
start_time   NaN
end_time     NaN
01 - Rental Details Rental ID      17536702.0
01 - Rental Details Local Start Time 2018-01-01 00:12:00
01 - Rental Details Local End Time   2018-01-01 00:17:23
01 - Rental Details Bike ID          3304.0
01 - Rental Details Duration In Seconds Uncapped 323.0
03 - Rental Start Station ID          69.0
03 - Rental Start Station Name        Damen Ave & Pierce Ave
02 - Rental End Station ID            159.0
02 - Rental End Station Name          Claremont Ave & Hirsch St
User Type                             Subscriber
Member Gender                         Male
05 - Member Details Member Birthday Year 1988.0
ride_id      NaN
rideable_type NaN
started_at    NaN
ended_at      NaN
start_station_name NaN
start_station_id NaN
end_station_name NaN
end_station_id NaN
start_lat     NaN
start_lng     NaN
end_lat       NaN
end_lng       NaN
member_casual NaN
Name: 1382225

```

Figure 1 Sample from python

saya akan memindahkan 2020 ke bagian folder kedua.

Lalu mengubah file 2018 Q1 menjadi format yang benar.

Setelah itu saya mengubah file dari list berikut dari start_time dan end_time format menjadi starttime dan endtime agar sama dengan format yang sudah ada.

Divvy_Trips_2017_Q1	6/11/2026 2:39 PM	Microsoft Excel C...	53,500 KB
Divvy_Trips_2017_Q2	6/11/2026 2:39 PM	Microsoft Excel C...	128,333 KB
Divvy_Trips_2017_Q3	6/11/2026 10:09 AM	Microsoft Excel C...	243,899 KB
Divvy_Trips_2017_Q4	6/11/2026 10:09 AM	Microsoft Excel C...	83,930 KB
Divvy_Trips_2018_Q1	6/11/2026 2:27 PM	Microsoft Excel C...	48,616 KB
Divvy_Trips_2018_Q2	6/11/2026 10:10 AM	Microsoft Excel C...	141,978 KB
Divvy_Trips_2018_Q3	6/11/2026 10:12 AM	Microsoft Excel C...	202,917 KB
Divvy_Trips_2018_Q4	6/11/2026 10:15 AM	Microsoft Excel C...	86,761 KB
Divvy_Trips_2019_Q1	6/11/2026 10:16 AM	Microsoft Excel C...	49,345 KB
Divvy_Trips_2019_Q2	6/11/2026 10:17 AM	Microsoft Excel C...	149,022 KB
Divvy_Trips_2019_Q3	6/11/2026 10:18 AM	Microsoft Excel C...	220,242 KB
Divvy_Trips_2019_Q4	6/11/2026 10:22 AM	Microsoft Excel C...	94,758 KB

Kenapa tidak dilakukan manual di excell adalah karena row excell tidak cukup untuk menampung filenya sehingga akan corrupt. Dengan demikian, kita akan menggunakan python agar aman.

```

folder_path = "tostarttimeandendtime"

for filename in os.listdir(folder_path):
    if filename.endswith(".csv"):
        file_path = os.path.join(folder_path, filename)

        df = pd.read_csv(file_path)
        diubah = False

        if "start_time" in df.columns:
            df.rename(columns={"start_time": "starttime"}, inplace=True)
            diubah = True
        if "end_time" in df.columns:
            df.rename(columns={"end_time": "endtime"}, inplace=True)
            diubah = True

        if diubah:
            df.to_csv(file_path, index=False)
            print(f"Berhasil mengubah kolom di file: {filename}")

Berhasil mengubah kolom di file: Divvy_Trips_2017_Q1.csv
Berhasil mengubah kolom di file: Divvy_Trips_2017_Q2.csv
Berhasil mengubah kolom di file: Divvy_Trips_2017_Q3.csv
Berhasil mengubah kolom di file: Divvy_Trips_2017_Q4.csv
Berhasil mengubah kolom di file: Divvy_Trips_2018_Q1.csv
Berhasil mengubah kolom di file: Divvy_Trips_2018_Q2.csv
Berhasil mengubah kolom di file: Divvy_Trips_2018_Q3.csv
Berhasil mengubah kolom di file: Divvy_Trips_2018_Q4.csv
Berhasil mengubah kolom di file: Divvy_Trips_2019_Q1.csv
Berhasil mengubah kolom di file: Divvy_Trips_2019_Q2.csv
Berhasil mengubah kolom di file: Divvy_Trips_2019_Q3.csv
Berhasil mengubah kolom di file: Divvy_Trips_2019_Q4.csv

```

Kita akan memulai lagi penyatuan worth of 3 GB file menjadi satu csv.

Ternyata di Divvy_Trips_2019_Q2.csv juga punya column name yang salah sehingga kita perlu ubah lagi di python dan memulai penyatuan ulang lagi.

Proses ini sebenarnya bisa diimporove kalau pakai if statement cuman biar saja sudah terlanjur dan cuman ada 2 file saja.

ubah semua endtime column jadi stoptime dan drop column jika ada birthday. Stoptime jadi endtime di sekitar 2017 dst, jadi kita perlu seragamkan nama columnnya dan birthday ada di 2013 akan kita drop saja karena cuman di situ yang ada yang lain ga ada.\

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 21243344 entries, 0 to 21243344
Data columns (total 12 columns):
 #   Column              Dtype
---  -
 0   trip_id             int64
 1   starttime           object
 2   stoptime            object
 3   bikeid             int64
 4   tripduration        object
 5   from_station_id     int64
 6   from_station_name   object
 7   to_station_id       int64
 8   to_station_name     object
 9   usertype            object
10   gender              object
11   birthyear           float64
dtypes: float64(1), int64(4), object(7)
memory usage: 1.9+ GB
```

2013-2020 data is done.

Sekarang saatnya data 2020-2026, kita akan menyamakan dengan data column dari 2013-2020 dan jika ada yang penting tidak kita drop biarkan 2013-2020 NAN jika itu penting untuk analisis.

ride_id
rideable_type
started_at
ended_at
start_station_name
start_station_id
end_station_name
end_station_id

start_lat
start_lng
end_lat
end_lng
member_casual

Perbandingan:

trip_id = ride_id

= rideable_type

starttime = started_at

stoptime = ended_at

bikeid = -

tripduration = - (bisa dibuat feature engginering)

from_station_id = start_station_id

from_station_name = start_station_name

to_station_id = end_station_id

to_station_name = end_station_name

usertype = member_casual (different name value)

gender = -

birthday = -

- = start_lat

--start_lng

--end_lat

--end_lng

Dengan demikian analisis pada gender dan tahun lahir hanya bisa dilakukan pada tahun 2013-2019 dan analisa pada jalur bersepeda cuman bisa dilakukan pada data tahun 2020-2026.

Tipe analisa:

Demograpy = data 2013-2019

Jalur sepeda = 2020-2026

Reideable_type = 2020-2026

Stasiun = semua data

Kita akan punya 3 file analisis. Sementara yaitu data 2013-2019, 2020-2026, dan keseluruhan data 2013-2019.

Data untuk 2020-2026 bersih tanpa perlu perubahan column:

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 33696132 entries, 0 to 33696131
Data columns (total 13 columns):
#   Column              Dtype
---  -
0   ride_id             object
1   rideable_type       object
2   started_at         object
3   ended_at           object
4   start_station_name  object
5   start_station_id   object
6   end_station_name   object
7   end_station_id     object
8   start_lat          float64
9   start_lng          float64
10  end_lat            float64
11  end_lng            float64
12  member_casual      object
dtypes: float64(4), object(9)
memory usage: 3.3+ GB
```

Sekarang tinggal **mengganti column name agar sama dan membersihkan value dari data dan assign data type ke setiap data** yaitu data 2013-2019 dan 2020-2026, setelah itu akan kita **gabungkan menjadi data ketiga** yaitu seluruh dataset.

Kita ganti column name dan yang tidak ada akan kita biarkan tetap sama. Karena ada perbedaan nilai di **"member_casual": "usertype"** maka kita akan mengubahnya.

Ini perubahan yang saya lakukan di beberapa column name 2020-2026 data:

```
df.rename(columns={"ride_id": "trip_id",
                  "started_at": "starttime",
                  "ended_at": "stoptime",
                  "start_station_id": "from_station_id",
                  "start_station_name": "from_station_name",
                  "end_station_id": "to_station_id",
                  "end_station_name": "to_station_name",
                  "member_casual": "usertype"
            }, inplace=True)
```

Pada data 2013-
value is:

Costumer & Subscriber

2020 usertype

Pada data 2020-2026 usertype value is:
member & casual

Kita akan menggunakan member dan casual sehingga 2013-2020 value akan kita ganti accordingly, ini untuk menyamakan penamaan dengan company gunakan yaitu member dan casual. Mapnya akan jadi Costumer:casual dan Subscriber:Member.

Saat mengubah data 2013-2020 saya menemukan bukan cuman ada Subscriber dan Costumer tapi juga ada ['casual', 'member', 'Dependent'] sedangkan data 2020-2026 hanya ada ['member', 'casual'].

Pada metadata yang disediakan juga tidak ada menyebutkan Dependent. Begini tulisanya:

usertype: "Customer" is a rider who purchased a 24-Hour Pass; "Subscriber" is a rider who purchased an Annual Membership.

Kita mencoba hitung berpada dependen yang ada di column usertype:

Jumlah row 'Dependent' : 190 baris

Total seluruh row data : 21,243,344 baris

Persentase : 0.0009%

Jadi hanya 190 row dan persentase sangat kecil dari 21 JT baris sehingga kemungkinan akan kita jadikan NAN atau masukan salah satu category karena dia tidak akan mempengaruhi analisa secara statistik dengan presentase sekecil itu.

Keputusanya adalah memasukan di member karena ada kemungkinan 'Dependent' adalah sebagai akun tanggungan remaja (16-17 tahun) yang didaftarkan di bawah akun utama 'Subscriber' (Annual Member). System ini merupakan data sistem lama dari Divvy System yang analis riset sendiri, walaupun tidak ada dokument tertulis yang bisa direfer. Namun, jikapun keliru dampaknya tidak akan masif dan mempengaruhi analisa atas costumer member dan casual karena tidak ada misal layanan vvip dan sebagiannya. Outliner tidak ada dan profit company adalah dari banyaknya (quantity) entah member atau casual.

Buat trip duration dengan mengurangi stoptime dengan starttime untuk data 2020-2026 – di round(0) dan formatnya tetap detik.

Bersihkan data sebelum assign type

Kita akan mulai dari 2013-2020 data lalu ke 2020-2026, kita akan check distinct, null dst untuk each column.

Several checklist for data clean process:

duplicate

Nan

Check unqiue value but not make sanse for example

Remove or add column

Standarized text or value

Min-max .describe() check if make sense

Logical check overall

2013-2020

birthyear

Gender dan birthday column punya masalah. Kalau kita ingat tugas utama kita adalah membedakan member dan casual, masalahnya di meta data ketika kita lihat, tertulis seperti ini:

** Gender and birthday are only available for Subscribers*

Harusnya ini bisa kita drop saja, namun data ini masih bisa berguna untuk satu alasan yaitu saya menulis: **maximizing annual member** maka *kita harus melihat juga apa kekuatan utama dari annual member yang bisa kita maksimalkan.*

Maka kita akan bersihkan saya dan tidak drop dengan alasan akan kita analisa untuk melihat kekuatan dari annual member. Kita akan mulai pembersihan dari data yang tidak make sense dan biarkan yang NAN, sample beberapa juga costumer cukup memberikan statistical signifikan untuk hal ini.

total null birthyear: 5.269.702

total birthyear exit: 15.973.642

setelah dibersihkan, kita akan membersihkan outlier dan menjadikanya null karena ada data yang tidak make sense misal:

birthyear | unique value

1759.0
1
1790.0
1
1888.0
20

Dst

Ini tidak make sense karena orang itu sangat tua, kita akan filter dari 1910 dan 2004, karena data untuk birthyear dan gender cuman ada di 2013-2020 dan usia maksimal 16

tahun sepertimana di aturan company:

SECTION 5 PROHIBITED ACTS.

a. You may not ride a Divvy bicycle if You are under 16 years of age. A minor who is 16 years of age or older may only use the Services if the minor's subscription is purchased by, and the minor is under the responsibility of, the minor's parent or legal guardian.

1940 dipilih karena itu batas umur yang mungkin untuk average manusia, 100 tahun naik sepeda pada 2013 possible tapi diatas itu kemungkinan sangat rendah dan tidak signifikan jikapun ada untuk Analisa.

2004 dipilih karena batas umur yang mungkin menurut aturan.

Gender

Untuk gender tidak ada masalah yang perlu diperbaiki.

Kita hanya akan ubah gender data type jadi category untuk efisiensi memory.

Trip_id

Trip_id is okey!

starttime

okey! Hanya ubah type dari object ke datetime

endtime

okey! Hanya ubah type dari object ke datetime

karena proses dari ubah starttime dan stoptime lama kita akan simpan dulu ke csv dari sini

sebelumnya, kita sudah menyimpan duplikat asli sebelum proses pembersihan ini di folder checkpoint jadi akan aman jika kita ubah-ubah.

data datetime di csv sudah aman dan seragam tapi biar datetime type sesuai saat di read kita pakai parsedate

Bike_id

Is okey everything good.

Tripduration

Trip duration kita ubah type dari object ke numeric, lalu kita ubah dari float ke int biar round ke detik.

Ada masalah di data ini yaitu soal sepeda hilang, dicuri, atau tidak dikembalikan.

Untuk aturan lebih lengkap bisa refer ke website: https://divvy-assets.s3.amazonaws.com/terms-and-conditions.html#section_3

Namun aturan yang berlaku secara sederhana adalah:

SECTION 3 LOST OR DAMAGED BICYCLES; KEY; ADDITIONAL FEES Di nomor aturan inilah poin utamanya berada. Di sini tertulis bahwa penggunaan sepeda dibatasi maksimal 24 jam berturut-turut. Jika lewat dari 24 jam, sepeda dianggap hilang/dicuri, kartu kamu akan didenda hingga \$1.200, dan pihak perusahaan bisa membuat laporan polisi. Kamu juga diwajibkan melapor ke polisi dan memberi tahu pihak perusahaan dalam waktu 24 jam setelah sepeda hilang.

SECTION 11 RETURNING BICYCLE Aturan ini menjelaskan bahwa jika sepeda tidak dikunci atau tidak dikembalikan dengan benar ke stasiun (not properly secured), maka sepeda tersebut tetap menjadi tanggung jawab penuh pengguna dan biaya sewa argo akan terus berjalan sampai sepeda terkunci sempurna.

SECTION 14 ADDITIONAL TERMS OF USE Pada paragraf keempat di aturan ini, ditegaskan kembali bahwa kamu harus melaporkan sepeda yang dicuri atau hilang kepada polisi dan pihak layanan pelanggan (Customer Services) Divvy sesegera mungkin, maksimal dalam waktu 24 jam.

Hal ini membuat keputusan untuk membatasi tripduration menjadi 24 jam atau dalam detik: 86400 detik. Row yang lebih dari itu akan dibuang untuk menyelamatkan operasional rata-rata yang tidak ada issue terkait pengembalian dan sebagainya.

Adapun data yang akan dibuang:

Jumlah perjalanan yang lebih dari 24 jam: 3,359 baris

Persentase data kotor: 0.0158% dari total data

Kehilangan atau issue tidak mengembalikan ini merupakan task business lain yang tidak ada dalam cakupan project ini dimana kita hanya memeriksa perbedaan antara member dan casual.

from_station_id and from_station_name

ada sekitar 96 stasiun dengan nama lebih dari 1.

Hal ini terjadi karena perbedaan input nama, misal :

437	[Washtenaw Ave & 15th St, Washtenaw Ave & 15th St (*), Washtenaw Ave & Ogden Ave (*), Washtenaw Ave & Ogden Ave]
-----	--

Id 437 punya banyak nama di inputnya, ini tidak akan diganti dan sebagiannya. Namun **saat analisis kita akan menggunakan id** bukan name. misal, untuk mencari rute tersibuk atau paling banyak dilewati member dst akan menggunakan id instead of name. from_station_name tidak akan di drop. Kita akan menggunakan name misal saat akan visualisasi, karena id tidak akan menunjukkan nama stationnya namun id lebih reliable untuk identifikasi.

Tidak ada pergantian type karena object sudah tepat karena berisi angka dan text di column ini.

to_station_id & to_station_name

sama seperti from_station column, ada 96 stasiun lebih dari 1 nama.

Kita akan pakai to_station_id untuk analisis dan tidak ada perubahan type karena sudah tepat.

Usertype

Oke! Hanya perlu ganti object jadi category biar hemat memory.

Done! Data 2013-2020.csv

Pembersihan untuk data 2020-2026

Trip_id

Oke nothing change.

Rideable_type

Akan diubah dari object ke category type karena cuman ada 4 type: ['docked_bike', 'electric_bike', 'classic_bike', 'electric_scooter']

starttime and stoptime

kita akan ubah dari object ke datetime, pakai format=mixed karena tidak tahu apakah formatnya selaras semua di seluruh data atau tidak. Walaupun lama tapi worth to wait.

from_station_name and from_station_id and to_station_id and to_station_id

ada masalah di station name dan station id sebanyak kurang lebih 5 jt value kosong

```
tf["from_station_name"].isnull().sum()

5096536

tf["from_station_id"].isnull().sum()

5097291
```

Setelah dicari tahu, alasan kosong adalah karena divvy sejak tahun 2020 memperkenalkan E-Bike (sepeda listrik). Berbeda dengan *docked_bike* (sepeda biasa) yang wajib diambil dan dikembalikan di stasiun resmi, pengguna E-bike bebas mengunci sepeda mereka di tiang rambu jalan, rak sepeda umum, atau di mana saja di dalam area wilayah operasional. Akibatnya, sistem tidak bisa merekam koordinat tersebut sebagai "Stasiun Resmi", sehingga kolom nama dan ID stasiunnya ditulis **kosong (NaN)**.

Untuk tahu lebih jelas dan dokumentasi resmi bisa dilihat disini:

<https://divvybikes.com/data-license-agreement>

<https://help.divvybikes.com/hc/en-us/articles/360046649911-Riding-with-an-ebike>

hal ini juga dikonfirmasi dari temuan data:

```
tf.loc[tf['from_station_name'].isnull(), 'rideable_type'].value_counts()

rideable_type
electric_bike      5028853
electric_scooter   67649
classic_bike        34
docked_bike         0
Name: count, dtype: int64
```

docked_bike adalah sepeda manual yang hanya bisa dikunci di slot stasiun.

Dengan demikian, kita akan isi NaN value tersebut dengan Id khusus dan Nama khusus. Kita akan melakukan imputasi. Dengan nilai berikut: **Id: 0 ; name: On-Street ;**

```
tf.loc[tf['to_station_name'].isnull(), 'rideable_type'].value_counts()
```

```
rideable_type
electric_bike      5269025
electric_scooter   70340
classic_bike       32858
docked_bike        9136
Name: count, dtype: int64
```

Ternyata di to_station_name misal ada sepeda classic yang juga ikut, ini kemungkinan data dari sepeda hilang or anyother issue. Kita akan tetap imputasi nilainya karena secara definisi dia diluar dari stasiun utama, kemungkinan mereka akan di drop ketika kita membersihkan tripduration.

Kita tidak akan ubah from_station_id dan to_station_id karena didalamnya ada campuran int dan huruf, jadi tetap object.

****notes:** ada perubahan yang terjadi di divvy company dari 2013-2020 ke 2020-2026 ; seperti pengenalan electrical vehicle, station bisa dibanyak tempat hence id jadi beragam bukan cuman format int untuk identifikasi ; saat analisa untuk geo atau stasiun gunakan id saja sebaiknya.

Tripduration

Kita akan membuat lagi detik yang lebih dari 24 jam karena bisa terjadi berbagai issue tadi (lihat pembersihan 2013-2020 untuk lebih detail).

jumlah perjalanan yang lebih dari 24 jam: 33332 baris

presentase data kotor: 0.0989% dari total data

total baris sebelum dibuang: 33696132

33,332 baris dibuang menjadi total baris saat ini: 33662800

start_lat and start_lng and end_lat and end_lng

ada 7,613 bari end_lat dan end_lng yang kosong setelah di check. Kemungkinan sama seperti kasus tripduration dan kemungkinan kesalahan lain juga seperti sepeda gps error, rusak dst. Kita juga akan membuang data sepeda ini karena berarti sepeda ini statusnya tidak diketahui dan ada issue di lapangan. Ini juga hanya presentase kecil 0.00% sekian dari total data jadi tidak masalah.

Usertype

Kita hanya akan mengganti dari object ke category, everything is oke.

2 data yaitu 2013-2020 dan 2020-2026 sudah selesai dibersihkan.

Karena ada 54 jt baris data, kita ubah dari csv ke parquet untuk mengkompresi ukuran dan agar tidak crash device saya karena kekurangan ram.

Data ketiga bisa dianalisa dan diambil datanya menggunakan parquet namun tidak bisa menampilkan seluruh data, hanya data yang dianalisa saja.

Ini sudah cukup untuk kebutuhan analisis karena kita tidak perlu melihat seluruh data.

3 data selesai yaitu 2013-2020, 2020-2026 dan 2013-2026.

Dengan demikian tahan proses sudah selesai, yaitu pembersihan data, pengumpulan data, dan penyimpanan data (internal).

ANALYZE

Dalam tahap analisi kita tetap harus membatasinya dalam batasan yang sudah ditentukan yaitu: **apa perbedaan casual dan member ; bagaimana maximizing member for profit ; convert casual into member.**

Apa yang akan kita lakukan?

Pertama, kita akan membaca seluruh basic stat dataframe atau file yang akan digunakan. Each column basic stat.

Kedua, kita akan melakukan univariate dari filter, sort, sampai visualisasi. Understanding data itself untuk each column.

Ketiga, Bivariate analysis dari filter, sort, visualisasi, korelasi, regresi, dan basic machine learning if needed. Understanding two variable or column given data set.

Keempat, kita akan melakukan multivariate analysis basic stat, filter, sort, visualisasi, korelasi, regresi, dan basic machine learning if needed. Understanding three or more variable or column given data set.

Definition for more clarification:

Basic stat would consist thing such as check for distribution, mean, median, count, top-n, lowest-n, sort by x, filter by x, as such.

Univariate analysis studies one variable at a time to understand its characteristics and distribution.

Bivariate examines the relationship between two variables to understand how they interact or influence each other.

Multivariate studies three or more variables together to understand complex relationships within the dataset.

mental model yang akan saya gunakan adalah top-down, which is hal general, dari seluruh dataframe -> each column statistics -> relationship and insight between one to more column -> relationship to business. Di tiap insight yang mungkin saya temukan akan saya tulis relevansinya pada business task.

Dataframe yang akan kita analisa adalah dataset lengkap 2013-2026.

Semua analisi dilakukan di python jupyter notebook – untuk lebih lengkap bisa melihat dokumentasi.

General dataframe statistics.

File name and type: divvy_total_2013_2026.parquet

File size: 2.01 GB

Jumlah baris: 54,936,117

Jumlah kolom: 17

Kolom name: ['trip_id', 'starttime', 'stoptime', 'bikeid', 'tripduration', 'from_station_id', 'from_station_name', 'to_station_id', 'to_station_name', 'usertype', 'gender', 'birthyear', 'rideable_type', 'start_lat', 'start_lng', 'end_lat', 'end_lng']

: ada sekitar 54 juta kurang lebih peminjaman sepeda selama durasi 13 tahun.

Note: Karena penggabungan data, akan ada beberapa column yang kosong lebih dari 50% misal. Hal ini tidak akan ditulis lebih jauh karena sudah dijabarkan pada penjelasan diatas. Tanda “:” akan digunakan sebagai insight yang berkaitan dengan business.

Each column statistics check

trip_id

ada temuan menarik di trip_id, selain karena jelas format berbeda era awal yang hanya ada sepeda biasa dengan era 2020 sekitar quarter 4, dimana menggunakan kombinasi angka dan huruf. Era awal trip id contoh: 4118 ; Era 2020 dan seterusnya: ADDAA33CEBCAE733.

Namun ada juga ternyata duplikat trip_id:

Total Baris: 54936117 | Total Unik: 54935601

Ada disparitas sekitar 516 baris dimana ia duplikat, karena itu akan di hapus salah satu.

Lalu, temuan menarik lainnya adalah saat proses pembersihan kita lupa accounted for – (minus) trip duration. Hal ini terjadi bisa karena error atau duplikat dan sebagiannya, karena itu akan kita drop juga.

Drop:

Duplikat trip_id

Minus tripduration

Tripduration minus akan kita urus duluan karena di duplikat beberapa kali minus kemungkinan karena tripduplikat, kalau kita urus trip_id duplikat dulu bisa saja yang tidak minus namun duplikat akan terhapus.

Total baris dengan durasi minus/nol : 14,990 baris

Persentase dari keseluruhan data : 0.0273%

Secara presentase tidak terlalu signifikan jadi akan kita drop.

Setelah minus tripduration di drop, data duplikat menjadi 307 saja.

Kita akan buang sekitar 307 data duplikat. Ini tidak signifikan secara statistik jadi tidak masalah dan ini hanya duplikat jadi tidak benar-benar bisa dihitung data yang valid.

Setelah di drop semuanya tidak ada lagi duplika di trip_id.

Total Baris: 54920820 | Total Unik: 54920820 (sama)

Total baris saat ini: **54,920,820**

Transaksi terakhir menggunakan sistem lama atau trip_id 25962904 terjadi pada: **2019-12-31 23:57:17**

Transaksi pertama menggunakan sistem baru atau trip_id 1068AB1B8F12FE23

Terjadi pada: **2020-01-01 00:04:44**

Starttime

Waktu paling awal dari data peminjaman adalah **2013-06-27 01:06:00**

Waktu paling akhir dari data peminjaman adalah **2026-05-31 23:57:08.778**

Beberapa pertanyaan bisnis yang bisa kita tanya:

: hari apa yang tidak ada in a whole dataframe dan mengapa?

Ada 4 tanggal dimana tidak ada transaksi peminjaman sepeda sama sekali.

	tanggal_kosong	nama_hari	tahun
0	2014-01-07	Tuesday	2014
1	2014-01-08	Wednesday	2014
2	2020-06-01	Monday	2020
3	2020-06-02	Tuesday	2020

Kemungkinan terjadi kesalahan dalam sistem atau pemeliharaan sistem karena 2 hari itu bergandengan. Misal, 2020 senin dan selasa terjadi kesalahan sistem atau pemeliharaan sistem karena itu data tidak ada – hal ini bisa berdampak misal saat kita membersihkan data, bisa saja data yang kita bersihkan merupakan bagian dari hari ini. Namun, karena ini hanya 4 hari dan hanya around 0.1% dari data kita, ini tidak signifikan namun cukup penting untuk dicatat – mostly karena kita harusnya tetap bisa mengambil data sebisa mungkin saat pemeliharaan sistem atau case hal-hal lain. Although ini part dari tim teknis data engineering.

:tanggal spesifik apa yang paling banyak dan sedikit peminjamnya exclude 4 data di atas?

--- 10 TANGGAL PALING RAMAI ---			
	tanggal_spesifik	total_peminjaman	nama_hari
0	2021-08-14	37324	Saturday
1	2021-07-17	37259	Saturday
2	2021-06-05	36695	Saturday
3	2021-06-19	36327	Saturday
4	2022-07-09	36145	Saturday
5	2021-07-31	35736	Saturday
6	2021-08-07	35574	Saturday
7	2023-06-10	35115	Saturday
8	2021-05-22	35017	Saturday
9	2022-04-23	34959	Saturday
--- 10 TANGGAL PALING SEPI ---			
	tanggal_spesifik	total_peminjaman	nama_hari
4708	2020-05-31	193	Sunday
4709	2019-01-30	163	Wednesday
4710	2015-02-01	141	Sunday
4711	2013-12-25	125	Wednesday
4712	2014-01-01	123	Wednesday
4713	2014-01-02	112	Thursday
4714	2013-06-27	95	Thursday
4715	2014-01-05	33	Sunday
4716	2014-01-03	6	Friday
4717	2014-01-06	1	Monday

yang paling menarik adalah **peminjaman paling banyak terjadi pada hari sabtu secara konsisten.**


Ini juga terlihat konsisten misal dari paling sepi, tidak ada hari sabtu. Dan kebanyakan terjadi di awal company berdiri pada 2014 atau 2013 dan terjadi lebih banyak pada awal bulan januari. Hal ini tidak mengherankan karena perusahaan baru berdiri dan bisa jadi libur awal tahun.

Ini menarik karena misal tim marketing bisa melakukan marketing base on hari. **Day-of-the-Week Marketing** misal dimana punya promo atau

diskon di hari tertentu. Targetnya akan jadi hari sabtu jika bisnis ingin menyasar kekuatannya or maximizing its strength.

: apa hari yang paling banyak dan paling sedikit data peminjamannya?

	nama_hari	total_peminjaman
0	Saturday	8411728
1	Friday	8059091
2	Thursday	7962337
3	Wednesday	7868892
4	Tuesday	7805935
5	Monday	7489772
6	Sunday	7323065



Hari paling BANYAK peminjaman: Saturday (8,411,728 transaksi)


Hari paling SEDIKIT peminjaman: Sunday (7,323,065 transaksi)

Anehnya, walaupun sama-sama weekend justru minggu transaksi sedikit terjadi dan sabtu terbanyak. Salah satu penyebab bisa jadi adalah ada lebih banyak event di hari sabtu dan the Sunday scary effect dimana orang tidak mau keluar rumah dan tidur terlalu malam untuk persiapan hari senin bekerja. Namun ini juga konsisten dengan data diatas bahwa sabtu adalah aktivitas paling sibuk dalam peminjaman sepeda.

Walaupun puncak hari paling banyak peminjaman adalah sabtu namun trendnya adalah senin dan minggu selalu rendah dan selasa-sabtu adalah clusture terbanyak aktivitas peminjaman.

*:apa **bulan** yang paling banyak dan paling sedikit data peminjamnya?*

	nama_bulan	total_peminjam
0	August	7747232
1	July	7678870
2	September	6981835
3	June	6632458
4	May	5794837
5	October	5524991
6	April	3754310
7	November	3183781
8	March	2687614
9	December	1858463
10	February	1618460
11	January	1457969



Bulan yang paling sedikit secara konsisten january dan february lalu desember. Awal dan akhir tahun secara konsisten jadi worst performance dari bisnsi ini. Mulai sekitar


mei dan puncaknya agustus lalu mulai menurun lagi di november mendekati akhir tahun. Jika kita pakai strategy maximizing kita juga akan maksimalkan marketing di pertengahan tahun dan menghindari bulan awal – jika strategy kita adalah diversifikasi atau menguatkan yang belum kuat maka target marketing kita haruslah awal atau akhir tahun.

:apa tahun paling banyak dan paling sedikit data peminjamnya?

	nama_tahun	total_peminjam
0	2024	5859492
1	2023	5718608
2	2022	5667186
3	2021	5594410
4	2025	5552573
5	2017	3829003
6	2019	3816156
7	2018	3601571
8	2016	3595333
9	2020	3530557
10	2015	3183439
11	2014	2454634
12	2026	1758070
13	2013	759788

Tahun paling banyak adalah 2024 dan paling sedikit adalah 2013 dimana tahun awal – mungkin karena tahun itu tidak lengkap **2013-06-27** adalah tahun paling awal data dan juga 2026 juga merupakan tahun yang tidak lengkap **2026-05-31 23:57:08.778**.


Namun kalau kita lihat trendnya, kebanyakan tahun awal belasan memang lebih sedikit daripada tahun 21 dan ke atas yang mendominasi. Kita akan coba melihat trendnya.



Dari trend yang ada (exclude 2013 dan 2026 karena tidak lengkap) ada long-term trend untuk tumbuh year on year dari peminjaman sepeda, namun di 2025 memang ada penurunan dari 2024, kita belum bisa mengambil kesimpulan dari 2026 yang akan datang karena datanya belum banyak dan belum melewati bulan penting seperti agustus.

:jam apa yang paling sibuk, paling senggang, dan distribusinya over 24 hours?

nama_jam	total_peminjam
0	584230
1	369921
2	224367
3	133426
4	131271
5	430137
6	1298663
7	2628041
8	3368486
9	2269233
10	2231125
11	2777939
12	3227602
13	3272176
14	3304601
15	3812470
16	5002307
17	5968302
18	4566838
19	3210817
20	2208948
21	1693312
22	1321433
23	885175



jam paling ramai adalah 17 atau 5 sore dan paling sepi adalah jam 4 subuh. Hipotesis saat ini kemungkinan itu jam pulang kerja, misal kita juga bisa liat kenaikan di jam 6 pagi dan seterusnya untuk aktivitas. Merendah ketika mulai jam 8 saat orang bekerja dan mulai meninggi lagi saat jam 3 dan seterusnya. Ini siklus yang cukup familiar untuk berangkat dan pulang kerja – namun itu masih hipotesis. Tidak salah juga ketika kita menyebut ini aktivitas normal manusia.

sedikit di hari tertentu?

:apakah ada anomali, sangat banyak atau sangat

Anomali yang mungkin adalah 4 hari yang tidak ada didalam data ini. Salah satu penjelasan yang mungkin adalah error system atau seluruh data di hari itu terbuang karena formatnya memang buruk dan lagi-lagi error system dalam pemasukan data.

STOPTIME

Column ini tidak akan dianalisa karena sudah cukup di starttime, dia akan dianalisa nanti saat hubungannya dengan variable lain misal. Saat ini fokus kita adalah each column – satu per satu saja.

BIKEID

Tidak ada yang cukup relevan untuk column ini karena perubahan sistem juga pada 2020 dan hanya ada informasi minimal seperti ada sekitar 6,526 unique bikeid. Kemungkinan ada segitu jumlah bike pada 2013-2020. Dari 54 jt data 33jt kosong yaitu perubahan sistem 2020-2026.

TRIPDURATION

Durasi di tulis dalam detik. Kita bisa jadikan dia ke menit.

Sepertinya ada terluap save hasil dari filter hanya boleh 24 jam max trip duration pada proses clean data karena itu saat di check max dia lebih banyak dari 24 jam, jadi akan di drop ulang:

Jumlah data yang melebihi 24 jam : 33,282 baris


Persentase data bocor : 0.0606% dari total data

*untuk alasanya kenapa bisa dilihat di bagain process di atas.

	tripduration	tripduration_minit
count	54887538.00	54887538.00
mean	1022.39	17.04
std	1971.22	32.85
min	1.00	0.02
25%	373.00	6.22
50%	654.00	10.90
75%	1160.00	19.33
max	86400.00	1440.00

karena filter hanya 24 jam which is an arbitrary number untuk lama penggunaan sepeda makanya max di 24 jam which is 1440 menit. Ini tidak masalah karena realitas di lapangan memang bisa demikian seperti lupa mengembalikan atau tidak jadi menggunakan seperti yang kita lihat di min 1 detik.

Yang penting misal adalah 17 menit rata-rata penggunaan dengan standard deviasi sekitar 32 menit. Berarti perilaku lama penggunaan menggunakan sepeda cukup beragam.



:Kita bisa dengan jelas melihat ada positive skew namun mayoritas pengguna ada dalam durasi 0-25 menit. Jadi kecenderungannya adalah short to medium range distance. Karena mayoritas penggunaannya dalam waktu singkat misal dari stasiun satu ke yang lain atau tempat satu ke tempat lain – prioritas bisnis misal adalah ketersediaan sepeda di jam sibuk dan titik-titik sibuk. Ini akan menjadi analisa tersendiri bila dipertanyakan lebih jauh untuk optimasi bisnis. Karena kita punya longitude dan latitude ini dimungkinkan.

Kita bisa melihat juga bahwa misal karena aktivitas yang pendek dan sering ini bisa jadi dilakukan warga lokal yang pergi bekerja atau ke suatu tempat. Sedangkan, long tail kemungkinan misal wisatawan. Ketika analisa dua variable kita bisa melakukan rata-rata penggunaan member dan casual. Kemungkinan akan ada data yang menarik.

Jumlah data yang kurang dari 2 menit: 1,486,797 baris

Persentase data : 2.7088% dari total data

:Data ini cukup signifikan, kita sejak awal memang tetap memasukan data yang kurang dari 2 menit. Ini mencerminkan anomali besar dimana orang yang ingin menggunakan armada sepeda itu tidak jadi menggunakannya. Masalahnya bisa karena entah pada kualitas sistem qr dan sebagiannya atau akibat dari sepeda yang tidak memadai. Ini bisa jadi user experience issue yang perlu diperbaiki. **Kita juga akan analisa ini dengan starttime untuk melihat tahun apa saja kejadian ini terjadi, dan apakah sudah ada perbaikan, bagaimana trend user experience di analisa dua variable nanti.**

Ada beberapa hal menarik lain misal total durasi atau jarak dari penggunaan sepeda dan sebagiannya. Ini sangat berguna misal untuk service dan mengetahui kapan waktu service dan sebagiannya. Namun ini tidak akan dilakukan disini. Alasan utama adalah karena itu bukan masalah bisnis kita dan kedua kita tidak punya cukup data untuk menilai individual sepeda karena tidak tersedia, ini akan jadi masukan yang bagus untuk tim engineering atau teknis misal untuk menambahkan data terkait.

from_station_id, from_station_name, to_station_id and to_station_name

2 column ini akan disatukan dalam analisa. Ingat alasanya di atas, singkatnya karena namanya ada yang mirip namun id really unique, sehingga saat analisa kita akan gunakan id dan ketika selesai analisa kita bisa menerjemahkan id ke name. begitu juga nanti to_station_id dan to_station_name.

Ternyata ada masalah!

1. id tidak reliable karena sistem berubah-ubah
2. nama juga tidak reliable karena beda nama

Jadi tiap sistem bisa berubah id-nya dan namanya, walaupun nama mirip, stasiun di lapangan ternyata sangat berubah-ubah membuat **from_station_id and from_station_name and to_station_id and to_station_name** harus di drop sebagai titik yang bagus untuk analisa. Multiple id on same name station dan multiple look like name with nan or id. Stasiun yang sama bisa selain berubah id juga berubah tempat, bergeser secara geografis akan menyulitkan untuk secara objektif menggunakan data ini. Namun, kita masih bisa menggunakan misal data spasial untuk melihat titik-titik dan stasiun yang sering dipakai. Walaupun secara garis besar titik kordinat ini sangat banyak namun kita bisa memangkas stasiun ini menjadi satu area besar sehingga kita punya semacam clusture stasiun di area tersebut, ini akan kita jadikan titik acuan sebagai tempat stasiun itu berada.

Dengan demikian akan diputuskan bahwa kita akan melewati ini dan pertanyaan bisnis misal:

:total stasiun aktif?

:stasiun paling ramai dan sepi?

Akan di alihkan ke 'start_lat', 'start_lng', 'end_lat', 'end_lng'; sebenarnya kita bisa pakai misal nama stasiun tapi akan sulit sekali untuk debug apalagi untuk melakukan regex karena complex dan bisa satu-satu, apalagi ada stasiun yang tersebar dimana-mana, kita tidak bisa menggunakan data itu. Berdasarkan cost-benefit adalah lebih baik menggunakan spasial data. Karena selain kemungkinan insight yang kita dapat akan sama walaupun tidak detail ke spesifik lokasi, namun area tertentu sudah cukup untuk

membuat kita bisa mengetahui area padat dan sebagiannya – mostly insight akan ada di sekitar apakah area member dan casual akan mirip atau berbeda. Kita juga misal bisa mengetahui soal area yang tidak diberi nama yang kemungkinan sering dipakai orang dengan e-bike. Walaupun data cukup terbatas sekitar 5 tahun namun secara statistic tetap signifikan.

start_lat, start_lng, end_lat and end_lng

ada sekitar 33,647,614 baris data dari 4 data ini. Sekitar 21,239,924 lainnya tidak ada, karena hanya ada di 2020-2026.


Untuk menggabungkan beberapa titik stasiun yang berdekatan kita akan rounding desimal langtitude dan longtitude jadi 4 desimal dimana stasiun yang berjarak kurang dari sekitar 11 meter akan di gabungan jadi satu stasiun yang sama.

:total stasiun aktif?


Total stasiun setelah di-rounding 4 desimal adalah: 64,504

Dengan merounding ke 4 desimal dan mencari setiap pasangan unik, ada sekitar 64,504 stasiun. Namun ini bukan stasiun fisik, karena ini adalah hasil kemungkinan dalam 2020-2026 letak dimana tempat sepeda bisa berada termasuk data dari sepeda yang ditaruh di tempat-tempat yang mana disetujui oleh divvy dan bisa juga tempat lain yang bisa mendenda pengguna.

:stasiun paling ramai dan sepi?



Berdasarkan data yang ada area dengan stasiun paling ramai dan aktivitas penggunaan banyak terjadi di area perkotaan dimana kepadatan penduduk dan jalan ada. Area dekat danau michigan. Tempat dimana pusat kegiatan seperti kantor dan area wisata seperti taman.



tempat dimana area sepeda (via google maps) yang ditandai hijau juga berada di sekitar sana.

Wilayah perbatasan chicao menjadi tempat yang memang lebih sedikit aktivitas manusia sekaligus tempat yang memang tidak banyak aktivitas peminjaman dan stasiun sepeda.

:dalam bisnis ini membuat penting untuk memeriksa service di tempat yang padat aktivitas dan memastikan ketersediaan sepeda ada. Jika strategy bisnisnya adalah memaksmlalkan. Misal kita lihat banyak data dimana less than 2 minute penggunaan sepeda. Ini menandakan kemungkinan sepeda yang rusak dan sebagiannya. Menjadi prioritas untuk diperhatikan.

:Jika kita lihat tempat spesifik maka **Streeter Dr & Grand Ave, DuSable Lake Shore Dr & Monroe St, dan Michigan Ave & Oak St** menjadi 3 tempat terbanyak aktivitas peminjaman sepeda. Ketiga tempat ini berada di pinggir danau michigan dan sekaligus tempat berfoto, berwisata, dan taman disekitar danau.

Kemungkinan orang yang ke sana adalah orang yang dari tengah atau sekitar kota, lalu memarkir sepeda di sekitar sana untuk bersenang-senang. Bisa juga dari sana ke arah rumah dan sebagiannya untuk kembali ke rumah atau hotel tempat menginap.

Hal ini bukan berarti dominasi ada di wisatawan. Penyumbang cluster besar lain juga merupakan warga lokal yang kemungkinan menggunakan sepeda untuk bekerja atau seperti data yang kita lihat di atas, pada hari sabtu pergi bersantai di sekitar kota.

Usertype

Harus diingat bahwa usertype ada dua tipe yaitu:

Casual : pengguna yang menggunakan sepeda dengan sistem harian atau by minute

Member: pengguna yang berlangganan tahunan atau bulanan

Tugas utama kita adalah memaksimalkan member dan membuat casual convert ke member. Dari usertype kita akan bisa melihat type pelanggan kita.

Pertanyaan yang mungkin:

: berapa banyak casual dan berapa banyak member?

usertype

member: 36,633,856

casual: 18,253,682

:harus dipahami bahwa ini bukan jumlah pengguna seperti member ada 36 juta dan sebagiannya. Data yang kita pakai adalah **Cyclistic's historical trip data** yang berarti ini adalah data perjalanan, ini justru menunjukkan bahwa member lebih sering menggunakan sepeda dari pada casual.

Cyclistic's finance analysts have concluded that annual members are much more profitable than casual riders. Although the pricing flexibility helps Cyclistic attract more customers, Moreno believes that maximizing the number of annual members will be key to future growth. Rather than creating a marketing campaign that targets all-new customers, Moreno believes there is a solid opportunity to convert casual riders into members.

:Walaupun lebih sering dipakai namun ternyata untuk bisnis lebih baik bahwa ada lebih banyak usertype yang member. Kemungkinan karena walaupun dipakai atau tidak, member tetap harus bayar dan uang dari member lebih mudah di prediksi untuk membayar biaya oprasional.

Analisi lebih jauh akan perbedaan behavior member dan casual akan lebih memudahkan kita. Ini akan dilakukan di analisis bivariate or multivariate analisis.

:rasio member dan casual?

usertype

member 0.667435

casual 0.332565

:Total perjalanan yang dilakukan oleh kelompok member adalah 2x lebih banyak daripada kelompok casual atau 0.67% secara ratio keseluruhan perjalanan.

:walaupun trip cost member lebih murah namun pelanggan tetap dan kepastian pendapatan menjadi modal growth jangka panjang yang bagus untuk perusahaan. Ketika fokus kita di casual ada biaya marketing dan akuisis pelanggan yang terus-terusan. Mungkin alasan ini menjadi poin yang ingin dicapai perusahaan. Long term growth over shortterm cash. Jika ada pelanggan tetapm bisnis kemungkinan membayar lebih di operasional esensial namun stabilitas terjaga.

Gender

Harus dipahami data ini terbatas. Hanya ada untuk subscriber (sekarang jadi member) dan hanya ada pada data 2013-2020 – sebagian nilai juga hilang. Data digunakan sebagian besar untuk analisi gender pada subscriber.

gender value count

nan 38,540,758

Male 12,234,756

Female 4,112,024

: Dari data yang tersedia (di luar data kosong sebesar 71%), tercatat pengguna berstatus member yang mengisi profil gender didominasi oleh laki-laki, dengan jumlah 3x lebih banyak daripada wanita.

:secara bisnis ini bisa berarti menargetkan marketing soal hal-hal yang lebih menarik laki-laki. Fokus pada efisiensi waktu, kecepatan membelah kemacetan kota, dan fitur kebugaran/olahraga (*fitness tracking*) atau simply social-culture base ads for example. Namun bukan berarti kita meminggirkan wanita, jika kita justru ingin ekspansi lebih ke pelanggan wanita dan memaksimalkannya maka buat hal-hal yang menarik perhatian wanita dan simply also social-culture base ads. Fokus pada aspek Keamanan dan Kenyamanan dan sebagainya.

Birthyear

Sama seperti gender, data ini hanya tersedia untuk subscriber dan hanya ada di 2013-2020 dataset. Kemungkinan akan digunakan untuk analisa maximizing subscriber (sekarang member) for more profit.

Most member by age:

1989.0 919298

1988.0	833274
--------	--------

1990.0	830614
--------	--------

1987.0	805677
--------	--------

1986.0	768481
--------	--------

: millenial atau orang yang berumur di range 35-40 merupakan member yang paling sering menggunakan sepeda. Kemungkinan karena mereka bekerja dan merasa kesehatan juga penting.

least member by age:

birthyear

1932.0	14
--------	----

1910.0	7
--------	---

1928.0	3
--------	---

1925.0	2
--------	---

1911.0	1
--------	---

:Kelompok lanjut usia menjadi yang paling jarang menggunakan layanan sepeda. Ini bisa mungkin karena umur namun juga bisa jadi kesalahan input data di lapangan. Namun ini cukup konsisten, selain 2004 yang memang tidak cukup umur misal di 30 user gender terendah angka tahun lahir umur lanjut usia konsisten hadir sebagai user terendah dalam penggunaan layanan. Untuk meningkatkan kita bisa marketing ke area kesehatan atau keamanan sepeda.

```

most member by age
birthyear
1989.0      919298
1988.0      833274
1990.0      830614
1987.0      805677
1986.0      768481
Name: count, dtype: int64

```

```

least member by age
birthyear
1943.0      2257
1939.0      2247
1940.0      1805
1918.0      1803
1941.0      1694
1942.0      1681
2003.0      1065
1921.0       981
1938.0       750
1934.0       568
1931.0       348
1930.0       242
1915.0       153
1929.0        85
1916.0        83
1912.0        57
1933.0        55
1935.0        50
1920.0        32
2004.0        31
1927.0        23
1936.0        19
1923.0        16
1922.0        16
1937.0        14
1932.0        14
1910.0         7
1928.0         3
1925.0         2
1911.0         1
Name: count, dtype: int64

```

rideable_type

harus diingat data ini hanya ada di 2020-2026 (sistem baru). Punya 4 kategori: ['docked_bike', 'electric_bike', 'classic_bike', 'electric_scooter']

docked_bike: (sepeda biasa) yang wajib diambil dan dikembalikan di stasiun resmi

classic_bike: Sepeda mekanik standar sistem baru. Biasanya lebih fleksibel atau memiliki sistem penguncian yang lebih modern dibanding *docked_bike*.

electric_bike: Sepeda berbasis motor listrik (e-bike) yang menawarkan kecepatan lebih tinggi dan efisiensi tenaga bagi pengendara.

electric_scooter: Skuter listrik, armada terbaru (skala mikro-mobilitas) yang biasanya menyasar perjalanan jarak dekat dan dinamis.

```

rideable_type
nan          21239924
electric_bike 16175008
classic_bike  13812384
docked_bike   3515886
electric_scooter 144336
Name: count, dtype: int64

```

nan karena rideable_type baru diimplementasikan di 2020-2026. Ingat dataset kita dari 2013-2026.

Kebanyakan menggunakan electric bike sebesar 16juta orang, classical bike 13jt orang, docked bike 3 juta orang, dan electric scooter 144 rb orang.

```

Rideable type ration exlude nan
rideable_type
electric_bike      0.480718
classic_bike       0.410501
docked_bike        0.104491
electric_scooter   0.004290
Name: proportion, dtype: float64

```

kebanyakan user menggunakan sepeda entah listrik atau biasa. Misal, 48% pengguna saat ini menggunakan electric bike, kemungkinan karena kenyamanan, kecepatan, dan alasan-alasan praktis lain. Dua sepeda itu bisa ditaruh dimana saja dan simply praktis.

:untuk bisnis ini bisa berarti menyediakan lebih banyak sepeda, jika ingin diversifikasi bisa memperbanyak dan marketing lebih di selain sepeda, yaitu scooter.

:99% pengguna menggunakan sepeda. Ada 2 kemungkinan dari electric scooter, data lebih lama akan mengungkapkan secara lebih jelas, kemungkinan pertama ia ditolak pasar (simply gagal membawa costumer) atau memang belum terlalu dikenal sehingga perlu marketing lebih jauh.


MULTI-ANALYSIS

Univariate analisi dan memahami a single column data lebih jauh akan efeknya terhadap bisnis sudah selesai. **Bivariate dan Multivariate analisis akan dilakukan secara bersamaan**, kita juga akan **lebih fokus pada pertanyaan bisnis** yaitu **membedakan member dan casual**. Karena, kombinasi atas berbagai variabel yang ada bisa sangat banyak, kita hanya akan memilih yang mana yang cocok dan menjawab pertanyaan bisnis yang kita hadapi.

Format yang akan digunakan adalah pertanyaan analisis dan jawaban atas pertanyaan tersebut.

Apakah ada perbedaan berdasarkan waktu (bulan, hari, jam) penggunaan layanan antara casual dan member?


Column needed: starttime, usertype




:Secara data keduanya sama-sama tidak terlalu ramai di awal dan akhir tahun. Mendekati atau menjelang pertengahan dan akhir tahun ia menjadi ramai pengguna. **Ini selaras dengan musiman** dimana desember-februari adalah musim dingin sehingga membuat user tidak banyak menggunakan layanan. Sedangkan puncaknya di musim panas antara juni-agustus menjadi hari dimana banyak aktivitas di luar rumah.

:kita juga bisa melihat bahwa ternyata member lebih loyal atau presisten terhadap cuaca, mereka tetap bersepeda di cuaca yang tidak baik, perbedaan puncak tertinggi ke puncak terendah hanya sekitar 4x. sedangkan **casual type lebih sensitif terhadap cuaca** dimana jumlah pengguna tertinggi dan terendah ada di sekitar 18x lebih tinggi atau rendah. Ini juga bisa dilihat dari grafik landai milik member dan grafik yang lebih curam oleh casual dan hanya terfokus di 3 bulan summer. **Dominasi casual ada di aktivitas rekreasi dan turis** sebagai contoh. Sedangkan kemungkinan **member ada di kegiatan harian seperti kerja**.

:Berdasarkan cost juga sebenarnya member akan merasa rugi jika tidak menggunakan membershipnya sehingga analisa apakah ini pelanggan yang memang menyukai sepeda, kebutuhan akan sepeda, atau tidak mau rugi juga menjadi analisa yang penting kedepan.



:perbedaan menarik juga terjadi di aktivitas harian. Member dominan penggunaan di awal minggu seperti senin sampai jumaat, ini menegaskan bahwa aktivitas member kemungkinan adalah untuk bekerja atau penggunaan sehari-hari berhubungan dengan pekerjaan. Sedangkan casual lebih banyak di sabtu dan minggu, dimana rekreasi menjadi alasan utama mereka. Member lebih sedikit justru di hari sabtu dan minggu. Perbedaan bisa dilihat dari minggu dan sabtu dibawah 4,3 juta aktivitas sedangkan di hari lain konsisten di angka 4,5 lebih. Begitu juga dengan casual, konsisten di bawah 3 juta ketika hari biasa dan konsisten di atas 3 juta hari weekend.



hal yang sama juga ditegaskan oleh jam penggunaan, cluster casual cukup landai dan meningkat di sekitar sore hari, sedangkan member cluster ada di dua titik, sekitar jam 6-8 dan 15-18. Jam pulang kerja. Harus diingat bahwa bukan berarti member selalu orang yang kerja dan sebaliknya casual selalu wisatawan atau rekreasi. Namun berdasarkan statistik kemungkinan besar dalam jumlah banyak ini yang terjadi.

Apakah ada perbedaan waktu tripduration antara casual dan member?

Column needed: tripduration, usertype

```

rata-rata penggunaan layanan casual vs member
usertype
casual    26.255605
member    12.447767
Name: tripduration_minute, dtype: float64

```

casual member lebih lama dalam penggunaan layanan. Hal ini disebabkan oleh mereka bersepeda bukan untuk kecepatan namun untuk rekreasi dan wisata di kota sedangkan member kemungkinan pergi dari satu stasiun ke stasiun lain atau dari satu tempat ke tempat lain sehingga menyebabkan durasi lebih pendek namun lebih sering. Polanya penggunaannya adalah:

Casual: lama namun jarang.

Member: cepat dan lebih sering.

```

median trip duration
usertype
casual    16.35
member    9.25
Name: tripduration_minute, dtype: float64

```


Hal ini juga dikonfirmasi dengan mdian trip duration. Rationya sama, casual around 2x lebih lama dari member.

	count	mean	std	min	25%	50%	75%	max
usertype								
casual	18253682.0	26.255605	47.846228	0.016667	8.783333	16.35	28.633333	1440.00
member	36633856.0	12.447767	20.324742	0.016667	5.533333	9.25	15.416667	1439.95

Meliat dari standard deviasi – terlihat bahwa casual lebih bervariasi dari member.

Apakah ada perbedaan durasi perjalanan berdasarkan bulan, hari, jam antara casual dan member?


Column needed: tripduration, usertype, starttime




:Hal yang menarik adalah seperti yang sudah kita ketahui bahwa variasi dan angka dari usertype member memang rendah – dan seperti yang bisa kita lihat variasinya pun rendah di chart bar yang ada. Misal, nilai tertinggi ke rendah yaitu 13.6 ke 10.8 cuman 1.2x, sedangkan kalau kita melihat dari casual yang nilainya bervariasi dan angkanya cukup tinggi, nilai tertinggi ke rendah bedanya 1.6x – hal ini juga menandakan bahwa

pengguna dari **member kebanyakan melakukan kegiatan yang monoton (stabil dan prediktif in a good sense) dalam penggunaan layanan.** Bahkan accros each month of the year.

:salah satu solusi yang menarik dari ini adalah bahwa kita harus meningkatkan penggunaan sepeda dari sekedar commute to work ke penggunaan daily untuk meningkatkan penggunaan member – salah satu contoh kita bisa mulai branding atau mencari sepeda yang cocok untuk olahraga. Olahraga bisa menjadi penggunaan lain dari sepeda selain pergi dari titik A ke Titik B. Olahraga juga bisa digunakan across every year of the month.



: dalam penggunaan harian member dari yang hari senin-jumaat konsisten di angka 12 menit menjadi lebih tinggi saat weeked. Ini menandakan perilaku menggunakan sepeda juga untuk rekreasi, sama seperti yang dilakukan oleh casual member. Berarti penggunaan membership saat bekerja sekaligus saat weekend untuk rekreasi. Begitu juga dengan yang dilakukan member casual, bukan hanya peningkatan di akhir pekan namun juga ada peningkatan cukup signifikan di hari senin. Ini termasuk anomali karena seolah-olah ada orang yang juga liburan banyak pada hari senin, jika ada data lebih soal demografi misalnya, anomali ini bisa dijelaskan, namun untuk sekarang mungkin kita bisa berasumsi industri yang ambil hari libur di hari senin atau orang yang bekerja tapi terlambat dan sebagiannya.



Pola durasi perjalanan member di sini terlihat konsisten dan hanya dengan sedikit perbedaan di pagi hari dimana pada sekitar pukul 5 ada valley. Kemungkinan orang ingin cepat ke titik yang dituju saja untuk kerja atau keperluan praktis.

: pola yang menarik adalah pada jam 7 pagi ke 10 pagi dimana tertinggi, ada pola trend kenaikan yang jelas. Asumsi kita di atas soal kemungkinan orang yang terlambat akibat minggu atau tidak sempat mengejar transportasi umum dan ingin cepat kerja, terpaksa harus menyewa layanan sesekali untuk mengejar waktu. Ini salah satu penjelasan yang mungkin dari anomali dan lonjakan ini – ini bisa juga jadi opportunity untuk mengembangkan pasar, hal ini berarti penetrasi kita ke pasar belum semaksimal yang bisa dilakukan. Kita punya peluang convert populasi ini menjadi member jika kita bisa meyakinkan dari pada hanya hari senin kenapa tidak tiap hari bersepeda, sehat dan cepat sampai tujuan sebagai contoh.

: **Product Repositioning** would be nice marketing strategy!!!

Apakah ada perbedaan antara stasiun/wilayah yang sering di datang antara casual dan member?

Column needed: start_lat, start_lng, end_lat, end_lng, usertype

Harus diingat bahwa data latitude dan longitude hanya tersedia di 2020-2026 data.

Break down pertanyaannya adalah:

1. analisis perbedaan jarak member vs casual dan Rute Bolak-balik (Round-Trip)
2. top tempat/stasiun member vs casual
3. clustering analysis member vs casual

Perlu dipahami bahwa data ini merupakan approximate jarak bukan jarak sebenarnya, kita tidak punya data actual meter or kilometer, karena itu kita gunakan rumus lingkaran bumi dan jarak beda antara start latitude & longitude dan end latitude & longitude.

	count	mean	std	min	25%	50%	75%	max
usertype								
casual	12920469.0	2.159304	2.018402	0.0	0.873458	1.636451	2.858100	48.898078
member	20719525.0	2.148301	1.914432	0.0	0.878115	1.560873	2.813103	48.658875

:Perhitungan di dasarkan KM (kilometer) – ada 12,9 juta data approx jarak casul dan 20,7 juta data approx jarak member. Rata-rata mereka mirip yaitu sejauh 2.1 km. ini berarti lamanya casual dan member trip duration tidak mencerminkan jarak mereka karena orang yang misal **pergi bekerja akan dengan cepat mengendarai sepeda** sedangkan **orang yang rekreasi bisa secara umum lebih lambat** – karena itu waktunya lebih tinggi.

Data ini juga dibatas 50 km karena kemungkinan ada kesalahan gps terjadi jika melebihi km ini dalam sehari.


```
round trip dimana sepeda yang digunakan di kembalikan di stasiun yang sama
usertype
casual      9.437320
member      4.000183
dtype: float64
```

Kita juga menganalisa round-trip, atau perjalanan dimana dari titik kordinat atau stasiun yang sama kembali lagi dari stasiun itu. Ada sekitar 9.4% pengguna casual mengembalikan sepeda di tempat yang sama dan 4% member mengembalikan sepeda di tempat dia menyewa.

: Tingginya angka pada pengguna *casual* mengonfirmasi bahwa kelompok ini mendominasi penggunaan sepeda untuk tujuan olahraga atau rekreasi. Hal ini membuka peluang strategi **Product Repositioning**. Kita bisa memanfaatkan data *round-trip* ini untuk meluncurkan produk *membership* khusus rekreasi (seperti *Weekend/Leisure Pass*) guna menangkap pasar *casual* yang aktif bersepeda secara rutin di akhir pekan, lalu mengukur pertumbuhannya dari waktu ke waktu.

Di sisi lain, angka *round-trip* pada **member** terbilang kecil (**4%**). Selain kemungkinan penggunaan untuk olahraga ringan atau keperluan mendesak di area sekitar stasiun,

secara operasional angka ini juga sering kali dipicu oleh faktor teknis—seperti pengguna yang mendapati sepedanya rusak sesaat setelah disewa, lalu langsung mengembalikannya ke stasiun yang sama untuk melakukan penukaran.



:Kita melakukan mapping pada 10 titik keberangkatan terbanyak antara member vs casual. Seperti yang bisa kita lihat hipotesis awal kita masih bertahan bahwa member banyak melakukan aktivitas di sekitar area padat kantor atau aktivitas ekonomi, politik dan sebagainya. Sedangkan casual berkluster di area sekitar lake michigan dimana taman dan tempat rekreasi. Jika fokus kita marketing secara geolocation untuk mengambil pasar casual menjadi member maka target kita adalah area sekitar lake michigan. Sebaliknya jika ingin memaksimalkan member, fokus pada area pada perkantoran dan pekerja.



Casual : jalur wisata

Member: pusat bisnis



Hal yang sama berlaku untuk titik tujuan, walaupun ada sedikit perbedaan misal di titik akhir member, namun klaster mereka tetap konsisten.

Berikut rute yang sering diambil oleh casual vs member:




E Grand Ave nampaknya menjadi pusat dari tujuan utama casual user. Sedangkan kebanyakan rute dari member adalah stasiun kereta dan juga sekitar kampus. Sepeda jadi penyampung stasiun kereta.

Apakah ada perbedaan jenis armada yang digunakan antara casual dan member?

Column needed: usertype, rideable_type

Harus diingat bahwa rideable_type hanya tersedia di data 2020-2026, jadi cukup terbatas.



	usertype	rideable_type	total_perjalanan
0	casual	classic_bike	4814836
1	casual	docked_bike	1703261
2	casual	electric_bike	6321634
3	casual	electric_scooter	85214
4	member	classic_bike	8997548
5	member	docked_bike	1812625
6	member	electric_bike	9853374
7	member	electric_scooter	59122

Seperti yang kita lihat perbandingan preferensi antara casual dan member hampir identik. Walaupun ada perbedaan sekitar 20jt data dari member dan 12,9 juta data dari casual.

Berdasarkan visualisasi proporsi armada di atas, meskipun kedua tipe pengguna sama-sama mendominasi penggunaan pada varian **electric_bike** (Casual: 48.9%, Member: 47.5%), terdapat perbedaan perilaku (*user behavior*) yang kontras pada pemilihan jenis armada lainnya:

1. **Preferensi Terhadap Fleksibilitas Armada:** Pengguna *Casual* memiliki persentase penggunaan **docked_bike** yang lebih tinggi (13.2%) dibandingkan *Member* (8.7%). Hal ini mengindikasikan bahwa pengguna *casual* tidak keberatan dengan keterikatan regulasi pengembalian sepeda pada dok resmi stasiun—sesuai dengan pola perjalanan wisata mereka yang terstruktur. Sebaliknya, *member* menuntut fleksibilitas tinggi demi mengejar efisiensi waktu komuter kerja.
2. **Pangsa Pasar Skuter Listrik (Micro-Mobility):** Volume perjalanan menggunakan *electric_scooter* pada kelompok *casual* (85.214) terpaut jauh di atas kelompok *member* (59.122). Ini menegaskan bahwa skuter listrik di lapangan dinilai lebih :

: Manajemen disarankan untuk terus melakukan peremajaan dan ekspansi pada lini *electric_bike* karena terbukti menjadi pendorong volume transaksi utama bagi kedua segmen pasar. Sementara itu, ketersediaan *docked_bike* generasi lama bisa dikonsentrasikan kelayakannya di stasiun-stasiun wilayah wisata pantai untuk mengakomodasi tingginya serapan dari pengguna *casual*.

Memami demografi berdasarkan member usertype, in case ingin lebih memaksimalkan member yang sudah ada strategy:

*ini kemungkinan akan ada di appendix karena bukan main task analis.

Batasan data ini adalah 2020-2026 dan hanya member yang ada.

Gender & Age


Gender vs tripduration

```
rata-rata trip duration by gender
gender
Female    14.890609
Male      12.280679
Name: tripduration_minute, dtype: float64
```

Rata-rata member yang melakukan trip duration lebih lama adalah wanita dengan rata-rata sekitar 14,9 menit. Hipotesis sementara adalah entah wanita lebih banyak

menggunakan sepeda untuk leasure atau tempat kerja wanita yang memang dominan lebih jauh dari pria.


Age + gender vs starttime



Secara rata-rata durasi perjalanan dalam menit, wanita memang melakukan perjalanan lebih lama dari laki-laki dalam umur apapun ini konsisten. Selain itu, ada kluster dimana umur 16-22 menjadi pemakai yang signifikan layanan kita. Namun, ada juga kluster lain di sekitar umur 60-70 – data birtyear ini sebenarnya harus divalidasi di lapangan, apakah data ini benar-benar valid atau hanya karena orang terlalu malas mengetik umur sebenarnya mereka. Namun jika benar bahwa data tersebut valid dan memang ada umur 60-70 yang nodabenenya sudah retire menggunakan layanan kita – berarti benar-benar ada potensi untuk branding ke arah olahraga dan manfaat kesehatan yang menargetkan senior citizen.

Average of tripduration_minute


Monthly average trip duration by gender




month ▼

Average of tripduration_minute

Day trip duration by gender



day ▼



Berdasarkan grafik perbandingan trip duration by gender – ada lonjakan signifikan disekitar waktu rekreasi di grafik biru atau gender wanita. Misalnya, gap awal dan akhir tahun by monthly wanita dan pria hampir mirip namun saat musim panas lonjakan perbedaan ini makin tinggi. Begitu juga saat kita atur by day yang menunjukkan lonjakan signifikan sekitar weekend. By hour kita lihat bahwa lonjakan justru ada di sekitar jam 10-15, perbedaanya jadi lebih besar daripada pengguna lelaki jika misal kita bandingkan pada pagi hari. Ini menandakan kebanyakan pengguna wanita memang menggunakan sepeda untuk selain transportasi kerja daripada laki-laki.

:salah satu keputusan bisnis yang baik dalam mempertahankan bahkan menambah customer wanita adalah dengan membuat sepeda secara optimal nyaman digunakan ; **feature seperti ada tempat untuk barang bawaan atau kenyamanan ux menjadi prioritas penting.**

Outline:

Title

Table of contents

Latar belakang: the bussines and senario that happen

businiess task: difference between member and casual usertype

Outline perbedaan berdasarkan category: demography, geography, duration time and ride type, by time (month, day, hour), usage type: kerja & leisure.

Explain finding

Aha moment: repositioning marketing and why we come up with it. Reason: usage type! How mostly all the things come down to how users use our service, it's the root.

Geography, time, demographics etc is just driven by how users use it. So the most effective change would be on perspective on how users use it.

Recommendation :

Product Repositioning Marketing. Dari penjelasan di aha moment kita ambil itu dan jadikan itu alasan kita merekomendasikan ini.

Appendix

About the process of cleaning and imputing and as such

About gender and age.

SHARE

The tool we will use is powerpoint and tableau since it's the best tool for presentation and data visualization.

powerpoint

Halaman 1

Title: Perbedaan antara tipe pengguna member dan kasual di perusahaan peminjaman sepeda Divvy

Subtitle: Analisis perbedaan tipe pengguna member dan casual sebagai sarana memahami strategy terbaik untuk marketing dalam memaksimalkan konversi user ke tipe pengguna member

Nama: Rahel

Tanggal: 16/6/2026

Halaman 2

Table of contents

- Latar belakang
- Bussines task (objective)
- Difference by category (explain finding)
 - Time of month, day, hour
 - Demograby
 - Geograpy
 - Duration time and ride type
 - Usage type
- Reccomendation action
- Appendix
 - Cleaning process and imputing
 - About maximizing profit (gender, age, trip duration)

Halaman 3

Latar Belakang

Divvy adalah perusahaan *Bike-share* yang di luncurkan sejak 2013 di Chicago. Pengguna bisa menggunakan sepeda dari berbagai stasiun yang disediakan dan mengembalikan ke stasiun manapun yang ada. Pengguna bisa menggunakan layanan dengan dua cara yaitu kasual dengan membayar berdasarkan berapa menit mereka menggunakan sepeda dan member dimana pengguna bisa berlangganan secara tahunan dan bebas menggunakannya sepanjang langganan berlaku.

Kita bekerja sebagai tim analist marketing di perusahaan Divvy Bikes. Bekerja sama dengan direktur marketing sebagai stakeholder untuk meyakinkan tim eksekutive terkait strategy marketing dari hasil analisa. Direktur marketing percaya **memaksimalkan**

angka langganan tahunan menjadi kunci sukses perusahaan. Dengan demikian, tim analist ingin **memahami bagaimana pengguna kasual berbeda dengan pengguna member.**

Halaman 4

Project Objektif: Mengidentifikasi **perbedaan perilaku antara pengguna *Casual* dan *Member*** berdasarkan **pola waktu, lokasi geografis, dan durasi berkendara**, guna merumuskan strategi pemasaran yang efektif untuk memaksimalkan langganan dan konversi keanggotaan tahunan.

Halaman 5

Time of month, day, hour viz

Explained

Halaman 6

Demograpy viz

Explained

Halaman 7

Geograpy viz

Explained

Halaman 8

Duration time and ride type viz

expalined

Halaman 9

Usage type viz

Explained

Halaman 10

Importance finding:

In summary what is the finding

Halaman 11

Reccomendation action

Halaman 12

Conclution

Another summary with recommendations actions

Halaman 13

Thank you

Halaman 14

Appendix

Tool used: python, excell, tableu

Dataset explained: 55jt baris etc

Data clean process and the reason we marge dataset etc

About maximizing profit (gender, age, trip duration)

Kesimpulan:

Dengan, menganalisa data Sejarah perjalanan Perusahaan peminjaman sepeda (Divvy) dari 2013-2026, sebanyak $\pm$ 54 Juta data. Baik berdasarkan Demografi, Waktu, Geografi, Durasi Waktu dan Tipe Kendaraan. Kita dapat menyimpulkan dua perbedaan besar antar Member atau Subscriber dan Casual atau Peminjam Harian yaitu berdasarkan Tujuan Kegunaan.

Member menggunakan layanan sepeda sehari-hari untuk transportasi bekerja atau untuk kegiatan-kegiatan yang memang mereka lakukan berulang kali setiap hari. Bagi member, sepeda memang kebutuhan dan untuk melakukan langganan berarti biaya per perjalanan mereka lebih kecil. Bagi Perusahaan tipe pengguna ini merupakan pemasukan stabil dan prediktif. Kemampuan tipe pengguna untuk menghasilkan pemasukan tetap dan setia pada layanan menjadi alat penopang bisnis yang baik.

Hal ini dibuktikan dari member yang punya cluster pada pagi dan sore hari serta penggunaan layanan yang terbilang lebih stabil dari casual dalam berbagai jangka waktu, begitu juga dengan stasiun-stasiun Tengah kota yang dekat dengan stasiun, pusat bisnis, dan pusat Pendidikan. Pola durasi perjalanan dan tipe kendaraan yang dipilih pun lebih cepat dan efektif untuk digunakan sehari-hari.

Casual menggunakan layanan sepeda untuk rekreasi dan bersantai dalam jangka waktu yang lebih Panjang namun tidak sesering member. Bagi casual, sepeda hanya merupakan salah satu moda transportasi yang digunakan Ketika memang butuh dan bila ingin menikmati waktu atau bepergian dengan santai. Bagi Perusahaan tipe pengguna ini merupakan pengguna yang lebih fluktuatif dan sulit diprediksi. Tipe ini bisa dibilang pelanggan yang belum setia maupun punya kebutuhan akan sepeda dalam kehidupan sehari-hari mereka namun tipe ini pula yang bisa menjadi target untuk konversi layanan.

Hal ini dibuktikan dari casual yang punya cluster pada sore hari saja serta pengguna layanan yang terbilang fluktuatif dari member dalam berbagai jangka waktu, begitu juga dengan stasiun-stasiun atau titik pinggir Danau Michigan yang menjadi dominasi dari casual, tempat wisata, tempat ikonik, taman, dan tempat terkenal lainnya. Pola durasi perjalanan dan tipe kendaraan yang dipilih pun lebih santai dan eksploratif untuk digunakan saat akhir pekan dan jika ingin bersantai.

Recommendation Action:

Fokus dari perbedaan ini ada pada tujuan dari penggunaan sepeda itu sendiri. Masalah yang mungkin dihadapi saat ini untuk konversi dari casual ke member adalah tidak ada kebutuhan untuk casual konversi ke member. Jika tidak ada kebutuhan untuk bekerja yang membutuhkan sepeda atau penggunaan sehari-hari maka sepeda tidak menjadi prioritas. Karena itu, merupakan tugas marketing untuk “menciptakan kebutuhan”.

Salah satu Teknik marketing yang sesuai Adalah **Product & Image Repositioning**. Dengan mengubah bagaimana cara orang melihat produk peminjaman sepeda kita bisa memperbesar pasar menjadi lebih inklusif dan menambah kegunaan dari peminjaman sepeda. Hal ini nantinya akan menciptakan kebutuhan itu sendiri. Sebagai contoh, kita bisa melakukan marketing dari segi manfaat bersepeda dengan mengiklankan sepeda

juga sebagai saran olahraga. Contoh iklan yang menarik, menunjukkan secara real bagaimana manfaat berkendara setiap pergi kerja atau ke tempat yang ingin dikunjungi secara akumulative pada tubuh.

ACT

Kita akan menyimpan seluruh presentasi, pdf, code ipynb, word, excel, data yang diperlukan (keseluruhan dataset tidak akan dimasukan karena terlalu banyak), data visualization, dan sebagiannya.

Kita akan mengirim hasil presentasi dan data visualization ke beberapa teman untuk feedback, jika buruk kita akan melakukan re-iterasi pada proses yang ada.

Kita juga akan share di linkeind.

Sebagai portfolio Data Analisis.

Diselesaikan pada: 20/6/2026